

WUM- Projekt 2: Klasteryzacja danych o kredytobiorcach

Cezary Polkowski
Alicja Przeździecka

O celu biznesowym

Za cel biznesowy uznaliśmy logiczny podział kredytobiorców na grupy w oparciu na zauważalne trendy, pozwalający na szybsze dostosowanie ofert kredytowych.

O Dataset-cie

- Dataset który był podstawą naszej pracy to:
 - <https://www.kaggle.com/datasets/n Ezekokamaado/auto-loan-dataset>
- Rozmiar tego datasetu (38000 wierszy) zapewnia brak problemów związanych z małą ilością danych
- Aby nasz model zwracał wiarygodne wyniki postanowiliśmy usunąć kolumny które są efektami podobnych analiz:
 - Grade – ocena kredytowa
 - Sub_grade – podkategoria oceny kredytowej
 - Int_rate – oprocentowanie
- To nie pozwala modelowi 'oszukiwać' poprzez branie pod uwagę tych odgórnie narzuconych statystyk

O modelu

- Nasz model jest modelem GMM - (Gaussian Mixture) z parametrami
 - Parametr `n_components=3` określa liczbę grup w danych.
 - `covariance_type='spherical'` zakłada, że wszystkie klastry mają identyczną wariancję w każdym wymiarze, co upraszcza model i redukuje ryzyko overfittingu przy braku wyraźnych korelacji między cechami.
 - `random_state=42` gwarantuje powtarzalność eksperymentu, co jest kluczowe w prezentacjach, aby wyniki mogły być zweryfikowane przez zespół lub klienta. Stałe ziarno losowości eliminuje przypadkowość, zwiększając wiarygodność rekomendacji biznesowych.

O doborze parametrów


Parametry zostały dobrane używając funkcji `grid_search` wykorzystujących wiele metryk oceniania jakości modelu, co zapewnia, że wybrane przez nas parametry dają najlepsze możliwe wyniki

Ostatecznie wybraliśmy model GMM zważając na porównywalne wyniki testów oraz lepiej wyglądające klastry w reprezentacjach wizualnych


Chcieliśmy uniknąć oczywistego podziału na osoby zatrudnione i nie, zatem postanowiliśmy wybrać podział na 3 klastry zamiast 2.

```
model, params, score
GMM, "k=2, covariance=full", 0.43836005456445354
GMM, "k=2, covariance=diag", 0.43836005456445354
GMM, "k=3, covariance=spherical", 0.16653504246475803
GMM, "k=2, covariance=spherical", 0.1515196617319988
GMM, "k=2, covariance=tied", 0.14696105311282823
GMM, "k=4, covariance=diag", 0.12714763719909497
GMM, "k=3, covariance=full", 0.12529622339808338
GMM, "k=3, covariance=tied", 0.12174736264603796
GMM, "k=6, covariance=spherical", 0.11844823995964789
GMM, "k=4, covariance=full", 0.11766435071762767
GMM, "k=6, covariance=tied", 0.11237730902947138
GMM, "k=7, covariance=spherical", 0.11197631426388051
GMM, "k=4, covariance=spherical", 0.11114743587725832
GMM, "k=5, covariance=spherical", 0.10958051175441849
GMM, "k=3, covariance=diag", 0.10907717062234029
GMM, "k=5, covariance=full", 0.10534213890567322
GMM, "k=4, covariance=tied", 0.09699999378269603
GMM, "k=7, covariance=tied", 0.09632678083758166
GMM, "k=5, covariance=diag", 0.0930680739572084
GMM, "k=5, covariance=tied", 0.09266822023400266
GMM, "k=6, covariance=diag", 0.07868652271935583
GMM, "k=7, covariance=diag", 0.04207249871756716
GMM, "k=6, covariance=full", 0.021475325467647303
GMM, "k=7, covariance=full", 0.004756193765427594
```


O podziale - zbiór Train




O podziale - zbiór Test




O podziale

- Klaster 0 (czerwony) - klienci ryzykowni - osoby niezatrudnione, osoby z zamożnych stanów
- Klaster 1 (żółty) - klienci z potencjałem ryzyka - niskie wartości kredytów, mniej kont bankowych, dużo klientów `source_verified`, klienci z mniejszym doświadczeniem zawodowym, klienci wynajmujący dom/mieszkanie, kredyty na 36 miesięcy, niższe dochody
- Klaster 2 (fioletowy) - klienci godni zaufania - wysokie wartości kredytów, więcej kont bankowych, dużo klientów ze statusem `verified`, klienci z większym doświadczeniem zawodowym, klienci spłacający dom/mieszkanie, wyższe dochody, częściej kredyty na 60 miesięcy
- Widzimy różnicę pomiędzy widokiem między t-SNE Train i t-SNE Test jednak na widoku UMAP widzimy, że kształty klastrów są te same co pokazuje że model sugerował się bardziej w sposób widoczny na wykresie UMAP.


UMAP colored by emp_length




UMAP colored by loan_amount




UMAP colored by total_acc




UMAP colored by 60_month_term



UMAP colored by home_ownership_RENT



UMAP colored by is_employed



O wiarygodności naszej pracy

- Stworzyliśmy kilkadziesiąt modeli i za pomocą różnych metryk wybraliśmy z nich najlepszy.
- Nasza praca była na bieżąco walidowana przez niezależny zespół ekspertów, którzy byli gotowi kwestionować nasze decyzje i proponować rozwiązania problemów

O wynikach

- Uważamy że nasz model ma praktyczne zastosowanie przy podziale kredytobiorców.
- Przykładowe zastosowania:
 - Wyniki pozwalają na lepsze zrozumienie, dlaczego klienci o zbliżonych cechach demograficznych czy finansowych mogą różnić się pod względem zachowań kredytowych, co przekłada się na efektywniejsze zarządzanie ryzykiem i personalizację oferty kredytowej.
 - Możliwość szybkiej i powierzchownej kategoryzacji klientów w celu zawężenia ilości informacji co potencjalnie może zwiększyć efektywność kredytodawców

Dziękujemy za uwagę